# Trabajo Práctico Especial Diseño de compiladores I

Número de grupo: 12

### Integrantes:

• Apraiz Thomás: tominola99@gmail.com

• Martinez Leanes Manuel: manumleanes@gmail.com

• Lujan Nicolas: Nico.L.2014@hotmail.com

### Profesor asignado:

• José Fernández León

Temas asignados: 3 7 (9) 10\* 13 18 20 (21) 22\* 24 27

# Índice

<u>Introducción</u>	3
Temas particulares asignados	4
Analizador léxico	5
Analizador sintáctico	11
Conclusiones	14

### Introducción

En esta primera etapa del trabajo práctico especial de la materia "Diseño de compiladores I" se desarrolló la parte léxica y sintáctica (con sus respectivos analizadores) de un compilador basado en características especiales de un lenguaje dado como consigna por la cátedra de la materia. Dicho compilador está implementado mediante una arquitectura monolítica en la cuál el parser es el main, "pide" tokens al Analizador Léxico y "entrega" reglas al Generador de Código.

El trabajo fue implementado en el lenguaje Java para la construcción del analizador léxico y sintáctico. Por otro lado se utilizó Yacc para la implementación del parser. En el siguiente informe se contemplan todas las técnicas y aclaraciones dadas por la cátedra para lograr un correcto funcionamiento de ambos analizadores.

# **Temas Particulares Asignados**

- Tema 3. Enteros (16 bits): Constantes enteras con valores entre –2 15 y 215 1. Se debe incorporar a la lista de palabras reservadas la palabra i16
- Tema 7. Punto Flotante de 32 bits: Números reales con signo y parte exponencial. El exponente comienza con la letra F (mayúscula) y el signo es opcional. La ausencia de signo, implica un exponente positivo. La parte exponencial puede estar ausente. Puede estar ausente la parte entera, o la parte decimal, pero no ambas. El "." es obligatorio. Ejemplos válidos: 1. .6 -1.2 3.F-5 2.F+34 2.5F-1 15. 0. 1.2F10. Considerar el rango 1.17549435F-38 < x < 3.40282347F+38 -3.40282347F+38 < x < -1.17549435F-38 0.0</p>
- Tema 10: Cláusulas de compilación
   Incorporar, a las sentencias declarativas, la posibilidad de definir constantes.
- Tema 13. Do until con continue: Incorporar a la lista de palabras reservadas las palabras do, until y continue.
- Tema 18. Continúe con etiquetado.
- Tema 20. Sentencia de control como expresión.
- Tema 22. Conversiones Implícitas
- Tema 24. Comentarios de 1 línea: Comentarios que comienzan con "<<" y terminan con el fin de línea.
- Tema 27. Cadenas multilínea: Cadenas de caracteres que comiencen y terminen con " ' " . Estas cadenas pueden ocupar más de una línea, y en dicho caso, al final de cada línea, excepto la última debe aparecer una barra " / ". (En la Tabla de símbolos se guardará la cadena sin las barras, y sin los saltos de línea).
   Ejemplo: '¡Hola /

mundo!'

# Analizador Léxico

# Consignas generales

Desarrollar un Analizador Léxico que reconozca los siguientes tokens:

- Identificadores cuyos nombres pueden tener hasta 25 caracteres de longitud. El primero debe ser una letra, y el resto pueden ser letras, dígitos y "\_". Los identificadores con longitud mayor serán truncados y esto se informará cómo Warning. Las letras utilizadas en los nombres de identificadores pueden ser minúsculas y/o mayúsculas.
- Constantes correspondientes al tema particular asignado a cada grupo. Nota: Para aquellos tipos de datos que pueden llevar signo, la distinción del uso del símbolo "-" como operador aritmético o signo de una constante, se postergará hasta el trabajo práctico Nro. 2.
- Operadores aritméticos: "+", "-", "\*", "/" agregando lo que corresponda al tema particular.
- Operador de asignación: "=:"
- Comparadores: ">=", "<=", ">", "<", "=", "=!" "(", ")", "{", "}", ", ", " y ";"
- Cadenas de caracteres correspondientes al tema particular de cada grupo.
- Palabras reservadas (en minúsculas): if, then, else, end-if, out, fun, return, break y demás símbolos / tokens indicados en los temas particulares asignados al grupo.

El Analizador Léxico debe eliminar de la entrada (reconocer, pero no informar como tokens al Analizador Sintáctico), los siguientes elementos:

- Comentarios correspondientes al tema particular de cada grupo
- Caracteres en blanco, tabulaciones y saltos de línea, que pueden aparecer en cualquier lugar de una sentencia.

# Decisiones de diseño e implementación

Para la realización de esta primera etapa se utilizó el lenguaje de programación Java. Se creó el Analizador Léxico el cuál se encarga de leer el programa fuente y de retornar un entero cada vez que reconoce un token por medio del método "yylex". Además cada vez que lee un carácter el Analizador Léxico cambia de estado (mediante una matriz de transición de estados) y ejecuta la acción semántica (Almacenada en una matriz de Acciones Semánticas) asociada a ese cambio de estado. El reconocimiento de un token por parte del Analizador Léxico se realiza mediante un diagrama de transición de estados (autómata finito) el cuál fué implementado con dicha matriz de transición de estados de tamaño NxM donde N es la cantidad de estados y M la cantidad de símbolos que se pueden reconocer. De la misma manera se creó la matriz de acciones semánticas la cuál almacena las distintas acciones que se deben tomar ante un cambio de estado (arcos del autómata). Ambas matrices son atributos que posee la clase Analizador Léxico y se pueden cargar dinámicamente por medio de métodos.

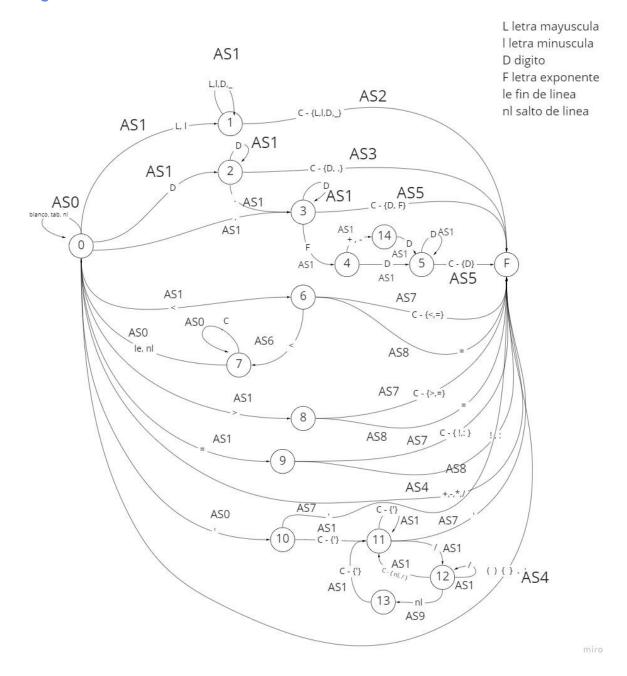
Por otro lado se implementó la clase **Tabla de Símbolos**, la cuál es una estructura de datos que almacena un registro para cada símbolo utilizado en el código fuente, con campos que contienen información relevante para cada símbolo (**Atributos**). Sólo se registran en la Tabla aquellos símbolos para los cuales pueden existir distintos lexemas para un mismo token. Dicha tabla implementó con un HashMap donde la clave es un String (Lexema del token) y el valor es el **Atributo**, es decir, otra clase en java la cuál es encargada de almacenar distintos tipos de información (Ej: Lexema, nro. de línea en que aparece el token, tipo, etc.) que se usarán en etapas posteriores (Generación de código). También se construyó una clase de **Tabla de Palabras Reservadas** la cuál almacena las distintas palabras reservadas del lenguaje y es usada tanto como por el analizador léxico y el sintáctico.

Con respecto a las **Acciones Semánticas** consideramos implementarla mediante una clase abstracta con el método abstracto de ejecutar donde cada acción semántica particular extiende de Acción Semántica y sobreescribe el método para realizar distintas acciones. Dicho método recibe como parámetros un *StringBuilder* que representa al token actual, y un *Reader* o lector encargado de leer el código fuente del programa.

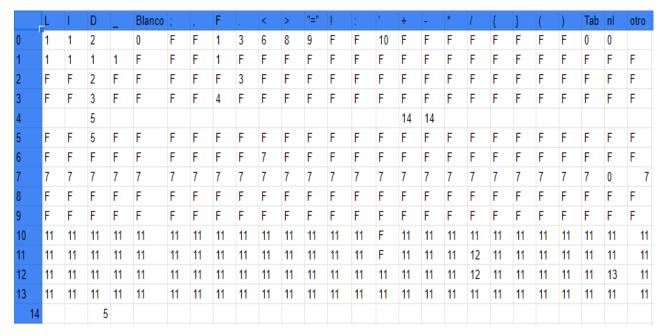
### Errores léxicos considerados

El Analizador Léxico puede producir ciertos warnings y errores a la hora de compilar el código fuente. Por ejemplo en el caso de los identificadores cuyo tamaño supere los 25 caracteres será truncado e informado como warning. Por el lado de los errores el Analizador Léxico puede detectar caracteres inválidos en el mapeo de los símbolos de entrada, las constantes fuera de rango y cuando el carácter de entrada no coincide con ninguno de los arcos de salida en un estado del autómata (Por ejemplo si se reconoce una F como exponente de un número flotante lo debe seguir obligatoriamente un dígito, sino da error).

# Diagrama de transición de estados

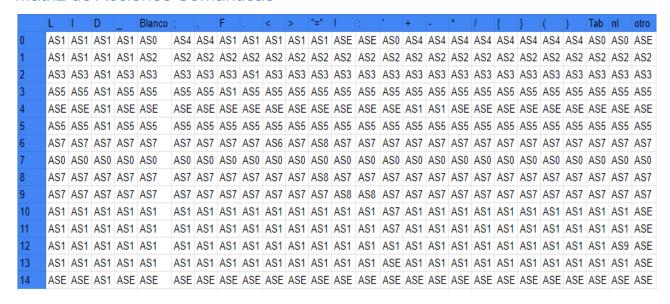


### Matriz de transición de estados



Aclaracion: los casilleros vacios indican que es un error.

### Matriz de Acciones Semánticas



# Acciones Semánticas implementadas

AS0: leer siguiente carácter.

AS1: concatenar el carácter leído.

AS2:

- -Devolver a la entrada el último carácter leído
- -Verificar rango ( < 25 caracteres)
- -Buscar en la TPR:
  - -Si está, devolver token de PR
  - -Si no está:
    - -Buscar en la TS:
      - -Si está, devolver ID + Punt TS
      - -Si no está: -Alta en TS -Devolver ID + Punt TS

### AS3:

-Agregar lexema a la tabla de símbolos (si no está), verificar rango de entero y devolver identificador del token.

AS4: Encargada de leer los símbolos: '+' '-' '/' '(' ')' ',' ';' '\*' , reconocer el literal, y devolver Token del mismo.

### AS5:

-Agregar lexema a la tabla de símbolos, verificar rango de flotante y devolver identificador del token.

### AS6:

Esta acción está destinada a los comentarios. Suprime el token leído hasta el momento, y lee el siguiente carácter. Ya que los comentarios no debemos enviarlos al Parser, no devolvemos el token correspondiente solo lo ignoramos.

### AS7:

Devolver el identificador del token correspondiente

### AS8:

Concatenar el carácter y devolver el token correspondiente

### AS9:

Borra el último carácter leído y lee el siguiente

### ASE:

Informa que hay error

### Pruebas

- Constantes con el primer y último valor dentro del rango (Archivo: prueba1). Con el archivo prueba1 testeamos tanto las declaraciones de variables enteras como flotantes. Se presentaron ciertos inconvenientes para arreglar como que no se puede realizar una declaracion y asignacion de una vez ya que la gramatica no lo permite. Otro inconveniente que se presenta es que cuando ponemos la letra F en un identificador, la reconoce como un solo token, lo cual esta mal.
- Constantes con el primer y último valor fuera del rango (Archivo: prueba2). Con este archivo se testea las constantes que estàn fuera de rango correctamente, el unico inconveniente es que se trunca mal las constantes flotantes.

- Para números de punto flotante: parte entera con y sin parte decimal, parte decimal con y sin parte entera, con y sin exponente, con exponente positivo y negativo (Archivo: prueba3).

Con prueba3 chequeamos el correcto funcionamiento de las constantes flotantes.

```
1 program {
2    f32 numeroflotante;
3    numeroflotante =: 32.5;
4    numeroflotante =: 32.;
5    numeroflotante =: .5;
6    numeroflotante =: 2.F4;
7    numeroflotante =: 2.F+4;
8    numeroflotante =: 2.F-4;
9 }
```

```
terminated> main [Java Application] C:\Program Files\Java\jre1.8.0_261\bin\javaw.exe (13-oct-2022 19:2
Identificador program
Palabra reservada f32
Identificador numeroflotante
Identificador numeroflotante
Constante flotante 32.5d
Identificador numeroflotante
Constante flotante 32.d
Identificador numeroflotante
Constante flotante .5d
Identificador numeroflotante
Constante flotante 2.E4d
Identificador numeroflotante
Constante flotante 2.E+4d
Identificador numeroflotante
Constante flotante 2.E-4d
Tabla de Simbolos:
32.d: Atributo [idToken=258, lexema=32.d, tipo=Float, line=4]
numeroflotante: Atributo [idToken=257, lexema=numeroflotante, tipo=, line=8]
32.5d: Atributo [idToken=258, lexema=32.5d, tipo=Float, line=3]
2.E+4d: Atributo [idToken=258, lexema=2.E+4d, tipo=Float, line=7]
program: Atributo [idToken=257, lexema=program, tipo=, line=1]
.5d: Atributo [idToken=258, lexema=.5d, tipo=Float, line=5]
2.E-4d: Atributo [idToken=258, lexema=2.E-4d, tipo=Float, line=8]
2.E4d: Atributo [idToken=258, lexema=2.E4d, tipo=Float, line=6]
```

- Identificadores de menos y más de 25 caracteres (Archivo: prueba4).

Con prueba4 comprobamos el correcto funcionamiento de los identificadores. Si se pasan de rango, los trunca a 25 caracteres.

- Identificadores con letras, dígitos y "\_" (Archivo: prueba4).

Con prueba4 tambien comprobamos el correcto funcionamiento de los identificadores.

- Intento de incluir en el nombre de un identificador un carácter que no sea letra, dígito o "\_" (Archivo: prueba5).

Con prueba5 comprobamos que si ponemos un caracter distinto a una letra, digito o '\_', el lexico lo reconoce como otro token y el sintactico lo informa como error.

- Comentarios bien y mal escritos (Archivo: prueba7).

Con prueba7 comprobamos que los comentarios funcionan correctamente.

- Cadenas bien y mal escritas (Archivo: prueba8).

Con prueba8 comprobamos que las cadenas no son reconocidas, debido a un error en el planteamiento de la accion semantica que devuelve la cadena.

- Palabras reservadas escritas en minúsculas y mayúsculas (Archivo: prueba6). Con prueba6 comprobamos que si usamos las palabras reservadas en mayusculas, se reconocen como un identificador, mientras que si estan en minusculas se reconocen correctamente.

```
1 program {
    <
📮 Console 🗶 🔝 Problems 🌖 Debug Shell
terminated> main [Java Application] C:\Program Files\Java\jre1.8.0_261\bin\javaw.exe (13-oct-2022 19:21:33 – 19:21
Identificador program
Palabra reservada i16
Identificador UNTIL
Palabra reservada if
Constante entera 12
Constante entera 13
Palabra reservada then
Identificador UNTIL
Constante entera 1
Palabra reservada f32
Palabra reservada until
Error yacc: syntax error
Error yacc: stack underflow. aborting...
Tabla de Simbolos:
12: Atributo [idToken=258, lexema=12, tipo=Entero, line=3]
1: Atributo [idToken=258, lexema=1, tipo=Entero, line=4]
13: Atributo [idToken=258, lexema=13, tipo=Entero, line=3]
program: Atributo [idToken=257, lexema=program, tipo=, line=1]
UNTIL: Atributo [idToken=257, lexema=UNTIL, tipo=, line=4]
```

En este caso, se reconoce la palabra reservada until como si fuera identificador, por lo tanto, es un error. Faltan correcciones de la gramatica, ya que para que en este caso funcione, debemos poner un doble punto y coma ";;".

# **Analizador Sintatico**

# Consigna General

Construir un Parser (Analizador Sintáctico) que invoque al Analizador Léxico creado en el Trabajo Práctico Nº 1, y que reconozca un lenguaje con las características dadas.

- a) Utilizar YACC u otra herramienta similar para construir el Parser.
- b) Adaptar el Analizador Léxico del Trabajo Práctico 1 para convertirlo en el método o función int yylex() (o el nombre que el Parser generado requiera). Tener en cuenta que el léxico deberá devolver al parser, en cada invocación, un token. Para los identificadores, constantes y cadenas, deberá devolver además, la referencia a la entrada de la Tabla de Símbolos donde se ha registrado dicho símbolo, utilizando yylval para hacerlo.
- c) Para aquellos tipos de datos que permitan valores negativos (i8, i16, i32, f32, f64) durante el Análisis Sintáctico se deberán detectar constantes negativas, modificando la tabla de símbolos según corresponda. Será necesario volver a controlar el rango de las constantes, ya que un valor aceptado para una constante por el Analizador Léxico, que desconoce su signo, podría estar fuera de rango si la constante es positiva. Ejemplo: Las constantes de tipo i16 pueden tomar valores desde –32768 a 32767. El Léxico aceptará la constante 32768 como válida, pero si se trata de una constante positiva, estará fuera de rango.
- d) Cuando se detecte un error, la compilación debe continuar.
- e) Conflictos: Eliminar TODOS LOS CONFLICTOS SHIFT-REDUCE Y REDUCE-REDUCE que se presenten al generar el Parser.

# Descripcion del proceso de desarrollo

Para realizar el trabajo práctico 2 lo primero que se hizo fué plantear la gramática del lenguaje dado por la cátedra. Las cuales se analizaron, revisaron y corrigieron en varias oportunidades para cumplir con los requisitos impuestos por el lenguaje. También se intentó formular reglas lo más claras y legibles posibles. Se tuvo que modificar y reescribir la gramática para que las sentencias declarativas pueden aparecer en cualquier lugar del código fuente, exceptuando los bloques de las sentencias de control. Por otro lado en el caso de las declaraciones de funciones el número máximo de parámetros permitidos es 2, y puede no haber parámetros, por lo tanto, tuvimos que hacer este chequeo durante el Análisis Sintáctico creando ciertas reglas para controlar esta restricción.

# Problemas surgidos y soluciones adoptadas en el proceso

Algunos problemas surgidos en la implementación de la gramática se dieron a la hora de los caracteres que encierran sentencias "{" "}" y el uso ";" al final de una sentencia por la recursión y las sentencias anidadas.

Por otro lado, cuando ya se implementó la gramática, surgieron ciertos problemas de reduce-reduce y shift-reduce, por ejemplo, en el caso de la sentencia if y de expresiones gramaticales por lo que se optó por modificar la gramática para solucionar estos inconvenientes. En el caso de las expresiones no se deben permitir anidamientos con paréntesis por lo que había que adaptar la gramática para la precedencia y asociatividad de las operaciones.

Otros problemas que surgieron fue que con la gramatica no se reconocen las constantes fueras de rango que son positivas ya que no se reconoce el operador '-' como signo de una constante. Por otro lado no se imprime por pantalla las distintas estructuras sintacticas detectadas.

Además se debió incorporar al léxico el símbolo ":", la palabra reservada end\_if, la palabra reservada const.

### Manejo de errores

El manejo de errores esta implementado mediante codigo asociado a algunas reglas de la gramatica e imprimiendo por pantalla los errores encontrados. Posteriormente, implementaremos los errores mediante clases y guardaremos los mismos junto a la linea en la que se produjo.

# Lista de no terminales usados en la gramática

- programa: Es la regla principal de la gramática (%start).
- nombre prog: Es la regla que nos indica el nombre del programa.
- cuerpo prog: Regla que sirve para la construcción del programa.
- bloque: Regla que permite definir bloques del programa.
- sentencia: Permite definir las distintas sentencias que puede soportar el parser.
- declaracion: Sirve para escribir distintos tipos de sentencias declarativas.
- declaracion const: Regla que permite reconocer constantes (tema 10).
- list const: Permite declarar recursivamente constantes.
- declaracion\_var: Regla utilizada para la declaracion de variables.
- lista de variables Permite declarar recursivamente variables.
- variable: Permite declarar variables con un ID
- tipo: Regla que permite definir tipos I16 o F32
- declaracion\_func: Esta regla sirve para declarar funciones en el programa.
- header\_func: Se utiliza para escribir correctamente el encabezado de una funcion.
- lista parametros funcion: Permite declarar los parametros de una función.
- cuerpo func: Regla que sirve para reconocer el cuerpo de una función.
- nombre func: Permite identificar el nombre de una función (ID).
- ejecucion: Regla que nos permite declarar distintos tipos de sentencias de ejecucion.

- asignacion:Esta regla permite declarar asignaciones con expresiones aritmeticas.
- expresion\_aritmetica: nos permite formar expresiones aritmeticas con distinta presedencia (La multiplicacion y division tiene mas presidencia que la suma) y asociatividad de simbolos (a izquierda).
- termino: Esta regla nos permite presedencia de simbolos.
- factor: Regla que usamos para determinar los simbolos terminales.
- lista\_inv\_func: Esta regla nos permite generara los parametros que puede recibir una funcion al ser invocada.
- seleccion: Regla que sirve para declarar sentencias de control IF
- then\_seleccion: Se usa para generar el cuerpo then de una seleccion y evitar conflictos de shift reduce.
- else\_seleccion: Se usa para generar el cuerpo else de una seleccion y evitar conflictos de shift reduce.
- condicion: Regla que determina la condicion que debe cumplir un if para ejecutarse.
- operador: Esta regla es utilizada para declarar los distintos operadores de comparación que puede tener una sentencia IF.
- impresion: Regla que nos permite reconocer sentencias para imprimir por pantalla.
- estruct do until: Permite declarar sentencias de do until.
- bloque\_do\_until: Esta regla sirve para poder declarar recursivamente bloques do until en otro bloque do until.
- etiqueta: Sirve para anteceder un bloque do until con una etiqueta.
- sentencia\_ctr\_expr: Esta regla permite declara sentencias do until con la posibilidad de devolver un valor utilizando la sentencia break, o un valor por defecto en la finalización normal de la sentencia.
- bloque\_do\_until\_expr: Permite la recursividad de bloques do until con sentencias control como expresiones.

### Pruebas

```
Identificador program
{
Palabra reservada i16
Identificador mivarentera
;
Palabra reservada fun
Identificador mifunc
(
Palabra reservada f32
Identificador parametro1
)
Error lexico en la linea: 6
Error yacc: syntax error
Error yacc: stack underflow. aborting...

Tabla de Simbolos:
mivarentera: Atributo [idToken=257, lexema=mivarentera, tipo=, line=4]
mifunc: Atributo [idToken=257, lexema=parametro1, tipo=, line=6]
program: Atributo [idToken=257, lexema=parametro1, tipo=, line=6]
```

Este caso se prueba en el archivo pruebaSintactico1, tuvimos un error en la matriz de acciones semanticas, donde cuando se reconoce un ':' desde el estado 0, lo informamos como un error.

### Salida:

```
Identificador program
Palabra reservada i16
Identificador suma
Identificador suma
Constante entera 5
Constante entera 7
Palabra reservada f32
Identificador op
Identificador op
Identificador suma
Constante entera 6
Constante entera 3
Identificador suma
Identificador mifun
Identificador op
)
Constante entera 3
```

```
Palabra reservada if
Identificador suma
Constante entera 3
Palabra reservada then
Identificador op
=:
Constante entera 4
Palabra reservada else
Identificador suma
=:
Constante entera 5
Palabra reservada end_if
Palabra reservada out
Identificador suma
}
Tabla de Simbolos:
suma: Atributo [idToken=257, lexema=suma, tipo=, line=17]
op: Atributo [idToken=257, lexema=op, tipo=, line=12]
mifun: Atributo [idToken=257, lexema=mifun, tipo=, line=9]
3: Atributo [idToken=258, lexema=3, tipo=Entero, line=11]
4: Atributo [idToken=258, lexema=4, tipo=Entero, line=12]
5: Atributo [idToken=258, lexema=5, tipo=Entero, line=14]
6: Atributo [idToken=258, lexema=6, tipo=Entero, line=8]
7: Atributo [idToken=258, lexema=7, tipo=Entero, line=6]
program: Atributo [idToken=257, lexema=program, tipo=, line=1]
```

En este caso, probado con el archivo pruebaSintactico2, reconoce correctamente las sentencias ejecutables. Tenemos un inconveniente con el out, ya que desde la gramatica no permitimos que reconozca nada mas que los identificadores.

```
1 program{
        <<Temas particulares
        const c1 =: 10;
        const x =: 5;
                continue : outer
                break 1;
 16 }
 < <
🦹 Problems 🏿 a Javadoc 🖳 Declaration 📃 Console 🗶
<terminated> Main [Java Application] C:\Users\Mercedes\.p2\pool\plugins\org.eclips
Identificador program
Palabra reservada const
Identificador c1
Constante entera 10
Palabra reservada const
Identificador x
Constante entera 5
Identificador outer
Error lexico en la linea: 5
Error yacc: syntax error
Error yacc: stack underflow. aborting...
Tabla de Simbolos:
5: Atributo [idToken=258, lexema=5, tipo=Entero, line=4]
x: Atributo [idToken=257, lexema=x, tipo=, line=4]
outer: Atributo [idToken=257, lexema=outer, tipo=, line=5]
program: Atributo [idToken=257, lexema=program, tipo=, line=1]
c1: Atributo [idToken=257, lexema=c1, tipo=, line=3]
10: Atributo [idToken=258, lexema=10, tipo=Entero, line=3]
```

En este caso, probado en el archivo pruebaSintactico3, tenemos el mismo error que en el caso 1, donde no se reconoce el ':' como primer caracter.

## Conclusiones

Con el desarrollo de los trabajos practicos 1 y 2, pudimos aprender el funcionamiento e implementacion de un analizador lexico y un analizador sintactico, como entre ellos se comunican para llevar a cabo la compilacion. En nuestro caso, aprendimos como funciona un compilador con arquitectura monolitica, donde el parser es el main y le pide tokens al lexico, para poder construir la lista de reglas de la gramatica.